Рубежный контроль №2

Близнева А.Е. группа ИУ5Ц-81Б

Вариант 26

Задание:

Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

О наборе данных:

Классификация типов звезд
Для сравнения всех моделей ML
Может использоваться для прогнозирования

Температура -- K
L -- L/Lo
R -- R/Ro
AM -- Mv
Color -- Общий цвет спектра
Spectral_Class -- O,B,A,F,G,K,M / SMASS - https:// en.wikipedia.org/wiki/Asteroid_spectral_types

Тип — Красный карлик, Коричневый карлик, Белый карлик, Основная последовательность, Супергиганты, Гипергиганты

ЦЕЛЬ:
Тип

от 0 до 5

Красный карлик - 0
Коричневый карлик - 1
Белый карлик - 2
Основная последовательность - 3
Супер Гиганты - 4
Гипергиганты - 5
МАТЕМАТИКА:

Lo = 3,828 x 10 ^ 26 Вт
(средняя яркость солнца)
Ro = 6,9551 x 10 ^ 8 м
(средний радиус солнца)

Импорт библиотек

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib
import matplotlib_inline
import matplotlib.pyplot as plt
from IPython.display import Image
from io import StringIO
import graphviz
import pydotplus
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error, median_absolute_e
from sklearn.ensemble import RandomForestRegressor
%matplotlib inline
%matplotlib inline
sns.set(style="ticks")
from IPython.display import set_matplotlib_formats
matplotlib_inline.backend_inline.set_matplotlib_formats("retina")
```

Загрузка данных

In [2]:
```
data = pd.read_csv('Stars.csv', sep=",")
```

Основные характеристики датасета

In [3]:
```
data.head()
```

Out[3]:

	Temperature	L	R	A_M	Color	Spectral_Class	Type
0	3068	0.002400	0.1700	16.12	Red	M	0
1	3042	0.000500	0.1542	16.60	Red	M	0
2	2600	0.000300	0.1020	18.70	Red	M	0
3	2800	0.000200	0.1600	16.65	Red	M	0
4	1939	0.000138	0.1030	20.06	Red	M	0

In [4]:
```
# Выведем размер датасета - по итогу получилось:
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
total_count = data.shape[1]
print('Всего колонок: {}'.format(total_count))
```

```
Всего строк: 240
Всего колонок: 7
```

In [5]:
```
# Выведем список колонок с их типами.
data.dtypes
```

Out[5]:
```
Temperature          int64
L                  float64
R                  float64
A_M                float64
Color               object
Spectral_Class      object
Type                 int64
dtype: object
```

In [6]:
```
# Проверил количество пустых значений по колонкам.
for col_empty in data.columns:
    empty_count = data[data[col_empty].isnull()].shape[0]
    print('{} - {}'.format(col_empty, empty_count))
```

```
Temperature - 0
L - 0
R - 0
A_M - 0
Color - 0
Spectral_Class - 0
Type - 0
```

Количество пустых значений означает, что все значения по этим колонкам заполнены.

Кодирование категориальных признаков

Преобразуем цвета и спектральные классы в числовые значения (label encoding)

In [7]:
```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

In [8]:
```
# Создаем новый фрейм данных, содержащий только столбцы типа object
obj_data = data.select_dtypes(include=['object']).copy()
```

In [9]:
```
obj_data.head()
```

Out[9]:

	Color	Spectral_Class
0	Red	M
1	Red	M
2	Red	M
3	Red	M
4	Red	M

In [10]:
```
data["Spectral_Class"].value_counts()
```

Out[10]:
```
M    111
B     46
O     40
A     19
F     17
K      6
G      1
Name: Spectral_Class, dtype: int64
```

In [11]:
```
data["Color"].value_counts()
```

Out[11]:
```
Red                    112
Blue                    56
Blue-white              26
Blue White              10
yellow-white             8
White                    7
Blue white               4
Yellowish White          3
white                    3
Whitish                  2
Orange                   2
yellowish                2
Yellowish                1
White-Yellow             1
Pale yellow orange       1
Orange-Red               1
Blue-White               1
Name: Color, dtype: int64
```

In [12]:
```
data["Color"] = data["Color"].astype('category')
data["Spectral_Class"] = data["Spectral_Class"].astype('category')
```

In [13]:
```
data.dtypes
```

Out[13]:
```
Temperature          int64
L                  float64
R                  float64
A_M                float64
Color             category
Spectral_Class    category
Type                 int64
dtype: object
```

In [14]:
```
data["Color_cat"] = data["Color"].cat.codes
data["Spectral_Class_cat"] = data["Spectral_Class"].cat.codes
data.head()
```

Out[14]:

	Temperature	L	R	A_M	Color	Spectral_Class	Type	Color_cat	Spectral_Class_cat
0	3068	0.002400	0.1700	16.12	Red	M	0	8	5
1	3042	0.000500	0.1542	16.60	Red	M	0	8	5
2	2600	0.000300	0.1020	18.70	Red	M	0	8	5
3	2800	0.000200	0.1600	16.65	Red	M	0	8	5
4	1939	0.000138	0.1030	20.06	Red	M	0	8	5

In [15]:
```
data = data.drop(columns='Color')
data = data.drop(columns='Spectral_Class')
```

In [16]:
```
data.head()
```

Out[16]:

	Temperature	L	R	A_M	Type	Color_cat	Spectral_Class_cat
0	3068	0.002400	0.1700	16.12	0	8	5
1	3042	0.000500	0.1542	16.60	0	8	5
2	2600	0.000300	0.1020	18.70	0	8	5
3	2800	0.000200	0.1600	16.65	0	8	5
4	1939	0.000138	0.1030	20.06	0	8	5

In [17]:
```
data.dtypes
```

Out[17]:
```
Temperature             int64
L                     float64
R                     float64
A_M                   float64
Type                    int64
Color_cat                int8
Spectral_Class_cat       int8
dtype: object
```

Масштабирование данных

In [18]:
```
from sklearn.preprocessing import MinMaxScaler
```

In [19]:
```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data)
sc1_data
```

Out[19]:
```
array([[2.96629095e-02, 2.73127546e-09, 8.29359490e-05, ...,
        0.00000000e+00, 5.00000000e-01, 8.33333333e-01],
       [2.89797956e-02, 4.94455040e-10, 7.48271124e-05, ...,
        0.00000000e+00, 5.00000000e-01, 8.33333333e-01],
       [1.73668585e-02, 2.59000259e-10, 4.80371586e-05, ...,
        0.00000000e+00, 5.00000000e-01, 8.33333333e-01],
       ...,
       [1.81025196e-01, 6.32776483e-01, 7.30304200e-01, ...,
        1.00000000e+00, 5.62500000e-01, 0.00000000e+00],
       [1.91692283e-01, 4.76725295e-01, 5.70693556e-01, ...,
        1.00000000e+00, 5.62500000e-01, 0.00000000e+00],
       [9.44352487e-01, 3.47181606e-01, 9.15062503e-01, ...,
        1.00000000e+00, 0.00000000e+00, 1.00000000e+00]])
```

Построим кореляционную матрицу

In [20]:
```
ig, ax = plt.subplots(figsize=(10,5))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.3f')
```

Out[20]:
```
<AxesSubplot:>
```

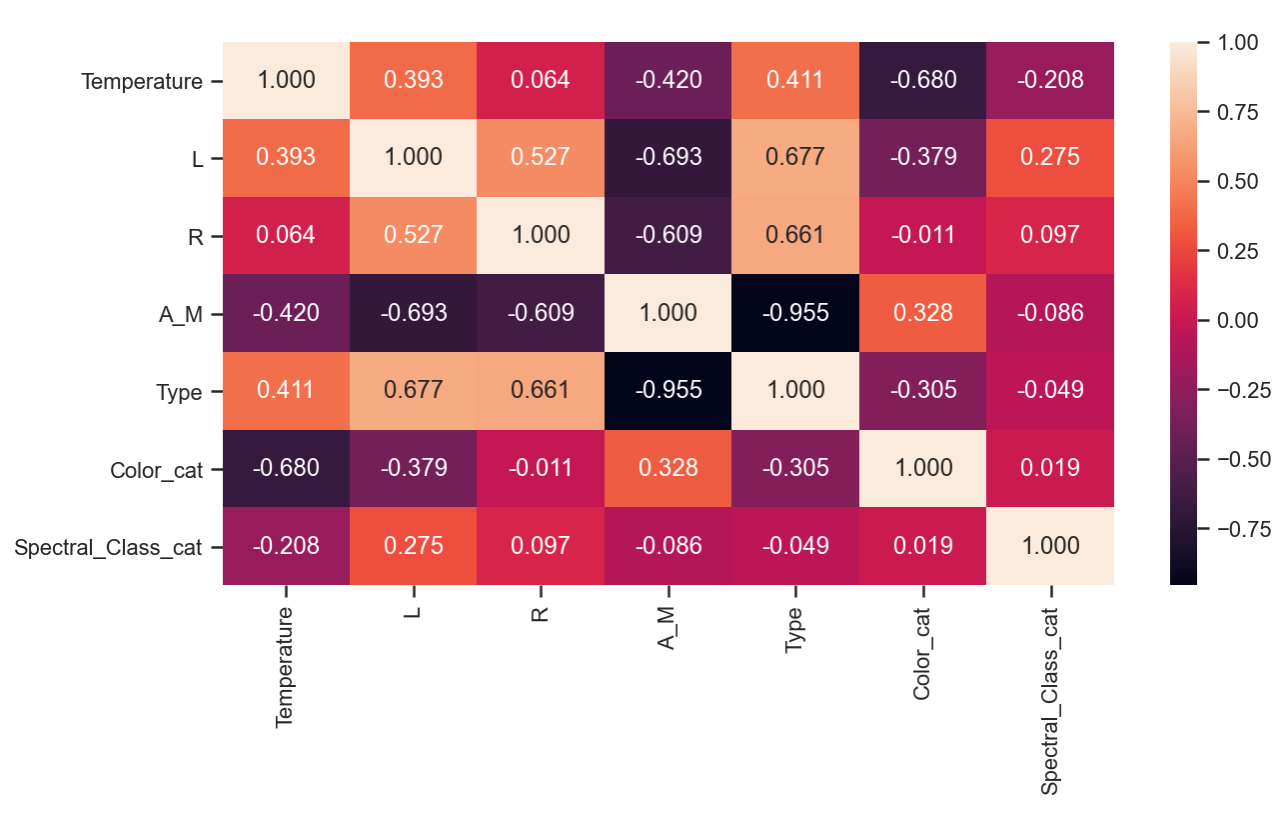

Предсказание целевого признака

Предскажем значение целевого признака L.

Разделение выборки на обучающую и тестовую

In [21]:
```
X = data.drop(columns='L')
Y = data['L']
```

Входные данные:

In [22]:
```
X.head()
```

Out[22]:

	Temperature	R	A_M	Type	Color_cat	Spectral_Class_cat
0	3068	0.1700	16.12	0	8	5
1	3042	0.1542	16.60	0	8	5
2	2600	0.1020	18.70	0	8	5
3	2800	0.1600	16.65	0	8	5
4	1939	0.1030	20.06	0	8	5

Выходные данные:

In [23]:
```
Y.head()
```

Out[23]:
```
0    0.002400
1    0.000500
2    0.000300
3    0.000200
4    0.000138
Name: L, dtype: float64
```

In [24]:
```
X_train, X_test, Y_train, Y_test = train_test_split(X, Y, random_state = 2023, tes
```

Входные параметры обучающей выборки

In [25]:
```
X_train.head()
```

Out[25]:

	Temperature	R	A_M	Type	Color_cat	Spectral_Class_cat
192	2994	0.28000	13.45	1	8	5
123	3146	0.09320	16.92	0	8	5
140	13420	0.00981	13.67	2	1	1
8	2650	0.11000	17.45	0	8	5
30	39000	10.60000	-4.70	3	0	6

Выходные параметры обучающей выборки

In [26]:
```
Y_train.head()
```

Out[26]:
```
192         0.00720
123         0.00015
140         0.00059
8           0.00069
30     204000.00000
Name: L, dtype: float64
```

Выходные параметры тестовой выборки

In [27]:
```
Y_test.head()
```

Out[27]:
```
42     150000.000000
205         0.001560
4           0.000138
120         0.000430
74          0.004000
Name: L, dtype: float64
```

Линейная регрессия

Метрики:
MSE - подчеркнуть большие ошибки
Median Absolute Error - оценить качество модели с устойчивостью к выбросам
R2 - точно и наглядно интерпретировать качество модели

In [28]:
```
reg = LinearRegression().fit(X_train, Y_train)
```

In [29]:
```
y_pred_test_reg = reg.predict(X_test)
y_pred_train_reg = reg.predict(X_train)
mse_reg = mean_squared_error(Y_train, y_pred_train_reg), mean_squared_error(Y_test, y_
mse_reg
```

Out[29]:
```
(13495193454.334732, 3325123742.294554)
```

In [30]:
```
med_reg = median_absolute_error(Y_train, y_pred_train_reg), median_absolute_error(Y_te
med_reg
```

Out[30]:
```
(36697.58446980551, 35483.77026547531)
```

In [31]:
```
r2_reg = r2_score(Y_train, y_pred_train_reg), r2_score(Y_test, y_pred_test_reg)
r2_reg
```

Out[31]:
```
(0.6052590715631364, 0.6474841820679058)
```

Случайный лес

In [32]:
```
rf = RandomForestRegressor(n_estimators=5, oob_score=True, random_state=1).fit(X_trai
```

```
C:\Users\Majer\anaconda3\lib\site-packages\sklearn\ensemble\_forest.py:833: UserWarnin
g: Some inputs do not have OOB scores. This probably means too few trees were used to
compute any reliable oob estimates.
  warn("Some inputs do not have OOB scores. "
```

In [33]:
```
# Out-of-bag error
rf.oob_score_, 1-rf.oob_score_
```

Out[33]:
```
(0.362018121029148, 0.637981878970852)
```

In [34]:
```
y_pred_test_rf = rf.predict(X_test)
y_pred_train_rf = rf.predict(X_train)
mse_rf = mean_squared_error(Y_train, y_pred_train_rf), mean_squared_error(Y_test, y_p
mse_rf
```

Out[34]:
```
(3062614212.8272805, 10915695442.398323)
```

In [35]:
```
med_rf = median_absolute_error(Y_train, y_pred_train_rf), median_absolute_error(Y_test
med_rf
```

Out[35]:
```
(0.00253, 0.0019330000000000003)
```

In [36]:
```
r2_rf = r2_score(Y_train, y_pred_train_rf), r2_score(Y_test, y_pred_test_rf)
r2_rf
```

Out[36]:
```
(0.910417054641995, -0.1572367242246857)
```

Сравнение моделей

In [37]:
```
print('MSE')
print('LinearRegression: ', mse_reg)
print('RandomForest:     ', mse_rf)
```

```
MSE
LinearRegression:  (13495193454.334732, 3325123742.294554)
RandomForest:      (3062614212.8272805, 10915695442.398323)
```

In [38]:
```
print('MedAE')
print('LinearRegression: ', med_reg)
print('RandomForest:     ', med_rf)
```

```
MedAE
LinearRegression:  (36697.58446980551, 35483.77026547531)
RandomForest:      (0.00253, 0.0019330000000000003)
```

In [39]:
```
print('R2')
print('LinearRegression: ', r2_reg)
print('RandomForest:     ', r2_rf)
```

```
R2
LinearRegression:  (0.6052590715631364, 0.6474841820679058)
RandomForest:      (0.910417054641995, -0.1572367242246857)
```

Вывод:

По результатам сравнения качества двух моделей на основе трех метрик - MSE, MedAE и R2, можно сделать вывод о том, что модель RandomForest показывает более высокое качество, чем модель LinearRegression. Это говорит о более высокой эффективности RandomForest в прогнозировании. Метрика R2, которая показывает, насколько хорошо модель соответствует данным, также подтверждает более высокое качество модели RandomForest.